

# DERİN ÖĞRENME İLE FELÇ (İNME) RİSKİ TAHMINİ(STROKE PREDICTION WITH DEEP LEARNING)

Efsa SEZER  
Bilgisayar Mühendisliği  
İstanbul Topkapı Üniversitesi  
İstanbul/Türkiye  
efsasezer@stu.topkapi.edu.tr

Asuman ULUSOY  
Bilgisayar Mühendisliği  
İstanbul Topkapı Üniversitesi  
İstanbul/Türkiye  
asumanulusoy@stu.topkapi.edu.tr

Mert Can SARIBIYIK  
Bilgisayar Mühendisliği  
İstanbul Topkapı Üniversitesi  
İstanbul/Türkiye  
mertcansaribiyik@stu.topkapi.edu.tr

Cevat RAHEBİ  
Yazılım Mühendisliği  
İstanbul Topkapı Üniversitesi  
İstanbul/Türkiye  
cevatrahebi@topkapi.edu.tr

**ÖZET :** Bu araştırma, derin öğrenme tekniklerini felç riski tahmininde kullanarak sağlık sektörüne yönelik bir inovasyon sunmaktadır. Büyük bir hasta veri seti üzerinde gerçekleştirilen çalışma, geliştirilen derin öğrenme modelinin mevcut yöntemlere kıyasla daha yüksek hassasiyetle felç riski tahminleri yapabildiğini göstermektedir. Klinik uygulamalarda kullanılabilirliği değerlendirilen model, erken teşhis ve müdahalede önemli bir artış sağlayarak hastaların yaşam kalitesini iyileştirebilir. Bu araştırma, derin öğrenme tabanlı analitik yöntemlerin sağlık sektöründeki potansiyelini vurgulayarak, felç riski tahminindeki mevcut sınırlamalara çözüm sunmayı amaçlamaktadır. Elde edilen bulgular, derin öğrenme modellerinin klinik uygulamalarda etkili bir şekilde kullanılmasının önemini vurgulayarak, sağlık profesyonelleri ve araştırmacılar için değerli bir kaynak sunmaktadır.

**ANAHTAR KELİMELE:** Felç Riski, Derin Öğrenme, Veri Analizi, İnme

## I. GİRİŞ

İnme, beyindeki kan damarlarındaki anormallikleri içeren ve beyin belirli bölgelerinde işlev bozukluğuna yol açan bir durumdur [6]. Beyin hücreleri kısa sürede ölmeye başlar ve inme oluşan bölgelerde geçici ya da kalıcı fonksiyon kayıpları meydana gelir. İnme ortaya çıktığında sadece fonksiyon bozukluklarına değil ölüme kadar uzanan sonuçlara neden olur. Geçmişten günümüze, sağlık sektöründeki teknolojik ilerlemeler, hastalıkların erken teşhisi ve tedavisi konusunda önemli bir evrimi tetiklemiştir. Bu evrim, özellikle felç gibi kronik ve ciddi sağlık sorunlarının yönetimi konusunda yeni perspektifler sunarak, hastaların yaşam kalitesini artırmayı ve sağlık sonuçlarını optimize etmeyi amaçlamaktadır.

Felç, dünya genelinde milyonlarca insanı etkileyen, kalıcı hasarlar bırakabilen ve ekonomik yükü önemli ölçüde artıran bir sorundur. Dünya Sağlık Örgütü'nün (WHO) raporuna göre felç, dünyada ikinci en yaygın küresel ölüm nedeni ve üçüncü en yaygın küresel sakatlık nedenidir [4].

Bu bağlamda, felç riskinin etkili bir şekilde tahmin edilmesi, erken müdahalenin ve kişiselleştirilmiş tedavi planlarının geliştirilmesinin temelini oluşturacaktır. Felç, erken müdahale edildiğinde ya da erken teşhis edilebildiğinde ölüm ya da kalıcı sakatlık riskinin yaklaşık %80 oranında engellenebildiği belirtilmektedir [1].

Geleneksel felç riski tahmini yöntemleri, genellikle demografik veriler ve belirli klinik ölçütler üzerinden yapılmaktadır. Ancak, bu yöntemler, genellikle sınırlı öngörü yetenekleri, düşük hassasiyet ve bireysel varyasyonları yakalama zorluğu gibi sınırlamalarla karşılaşmaktadır. Bu nedenle, bu çalışma, derin öğrenme tekniklerinin felç riski tahmini alanında nasıl kullanılabileceğini araştırarak, mevcut sınırlamalara çözüm sunmayı amaçlamaktadır.

Derin öğrenme, büyük veri setleri üzerinde karmaşık ilişkileri çıkarma ve öğrenme yeteneğiyle ön plana çıkan bir yapay zeka dalıdır. Bu çalışma, derin öğrenme algoritmalarının, felç riski tahminindeki potansiyelini detaylı bir şekilde incelemekte ve bu tekniklerin, özellikle büyük ve heterojen veri setlerinde geleneksel yöntemlerden daha etkili olabileceği hipotezini test etmektedir. Bu bağlamda, geliştirilen modelin, geniş bir hasta veri seti üzerinde kapsamlı bir şekilde test edilmesi ve mevcut yöntemlere kıyasla daha yüksek bir başarı oranı elde etmesi, derin öğrenme tabanlı felç riski tahmini modellerinin potansiyelini vurgulamaktadır.

Sonuç olarak, bu çalışma, derin öğrenme tekniklerinin felç riski tahmini alanındaki önemini vurgulayarak, bu teknolojik gelişmelerin hastaların yaşam kalitesini artırmak adına nasıl bir çözüm sunabileceğini tartışmayı hedeflemektedir. Bu çaba, gelecekteki sağlık uygulamalarında daha hassas, güvenilir ve erken müdahale odaklı bir felç riski tahmini modelinin geliştirilmesine katkı sağlama amacını taşımaktadır.

## II. LİTERATÜR TARAMASI

Yaptığımız literatür taraması, derin öğrenme modellerinin felç riski tahminindeki etkinliğini ve potansiyelini değerlendirmek üzere bir dizi önemli çalışma içermektedir. Bu çalışmalar, derin öğrenme modellerinin büyük veri setleri üzerinde daha hassas tahminler gerçekleştirebildiği ve klinik uygulamalarda önemli avantajlar sağlayabileceği konusunda güçlü kanıtlar sunmaktadır.

Bu bağlamda yapılan bir derleme, derin öğrenme modellerinin sadece felç riski tahmininde değil, aynı zamanda hastaların genel sağlık durumlarını anlamada ve bireyselleştirilmiş tedavi planları oluşturmada önemli bir rol oynayabileceğini vurgular. Aynı zamanda derin öğrenme tabanlı analitik yöntemlerin felç riski tahminindeki potansiyelini vurgulayarak, mevcut yöntemlerin sınırlamalarına çözüm sunmayı amaçlamaktadır [2]. Benzer bir konuda gerçekleştirilen bir meta-analiz çalışması, derin öğrenme modellerinin geleneksel yöntemlere göre üstün bir performans sergilediğine dair güçlü kanıtlar sunmaktadır [3]. Cheon ve ark. (2019), felci tespit edebilmek için sağlık davranışlarını ve medikal hizmet kullanımını temel alan bir çalışma gerçekleştirmişlerdir. Çalışmada 15.099 adet felçli hastadan topladıkları verilerle derin öğrenme yöntemi kullanılarak felç tespiti yapılmıştır. Veri ön işleme aşamasında PCA kullanılarak veriler üzerinde boyut azaltma işlemi gerçekleştirilmiştir. Derin öğrenme ile gerçekleştirilen tahmin işleminde %83,48 AUC değerine ulaşıldığı rapor edilmiştir [14].

Felç riski tahmininde derin öğrenme modellerinin kullanımını ele almanın yanı sıra, farklı veri tiplerini ve çeşitli görüntüleme modellerini içeren geniş bir perspektif sunan bir diğer çalışma derin öğrenme modelinin uygulanabilirliğini artırmak ve güvenilirliğini sağlamak için kullanılan veri argümentasyonu ve transfer öğrenme gibi tekniklere odaklanmaktadır [11].

Bir başka meta-analiz çalışması ise derin öğrenme modellerinin sadece felç riski tahmininde değil, aynı zamanda hastane içi ve hastane dışı felç sonuçlarını öngörme yeteneklerini ele almaktadır. Derin öğrenme modellerinin çeşitli hasta grupları ve demografik özelliklere uyarlanabilirliğini değerlendirerek, bu modellerin geniş bir uygulama yelpazesi içinde etkili olduğunu göstermektedir [12].

Bu bulgular, derin öğrenme tabanlı felç riski tahmininin sadece bilimsel bir ilgi alanı olmanın ötesinde, gelecekteki sağlık uygulamalarında önemli bir rol oynayabileceği konusunda değerli bir perspektif sunmaktadır [2]. Bu alandaki ilerlemeler, erken teşhis, bireyselleştirilmiş tedavi planları ve sağlık hizmetlerinin optimize edilmesi gibi kritik alanlarda önemli etkiler yaratabilir [3]. Bu nedenle, derin öğrenme tabanlı felç riski tahmini, sağlık sektörünün daha etkili, erişilebilir ve kişiselleştirilmiş hale getirilmesine katkıda bulunma potansiyeli taşımaktadır.

## III. MATERYAL & METOT

### A. VERİ TOPLAMA

Bu çalışmanın temelini, sağlık sektöründeki felç riskini tahmin etmeye yönelik bir veri seti oluşturmak oluşturur. Veri seti, sağlık kayıtlarını içeren ve Kaggle platformunda "Stroke Prediction Dataset" olarak bilinen bir veri setidir. Toplamda 5110 veri noktasına sahiptir ve çeşitli demografik, tıbbi ve yaşam tarzı özelliklerini içermektedir. Özellikler arasında yaş, cinsiyet, hipertansiyon durumu, kalp hastalığı geçmişi gibi bilgiler bulunmaktadır. Veri seti, inme geçirip geçirmediğini belirten bir hedef değişken içermektedir.

Çizelge 1. Veri setimizin ilk hali

	id	gender	age	hypertension	Heart_disease	Ever_married	Work-type	Residence_type	Avg_Glucose level	bmi	Smoking_status	stroke
0	9046	Male	67.0	0	1	Yes	Private	Urban	228.69	36.6	Formerly Smoked	1
1	51676	Female	61.0	0	0	Yes	Self-Employed	Rural	202.21	NaN	Never Smoked	1
2	31112	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	Never Smoked	1
....	....	....	...	.....	.....	.....	.....	.....	.....	.....	.....	.....
5106	44874	Female	81.0	0	0	Yes	Self-Employed	Urban	125.20	40.0	Never smoked	0
5107	19723	Female	35.0	0	0	Yes	Self-Employed	Rural	82.99	30.6	Never smoked	0
5108	37544	Male	51.0	0	0	Yes	Private	Rural	166.29	25.6	Formerly Smoked	0
5109	44679	Female	44.0	0	0	Yes	Govt_job	Urban	85.28	26.2	Unknown	0

## B. VERİ GÖZLEMİ

Veri setinin gözlenmesi, eksik verilerin tespiti, tekrar eden değerlerin kontrolü ve temel istatistiksel bilgilerin incelenmesi adımlarını içerir.

Çizelge 1’de veri setimizin işlenmemiş ilk halini görmektedir. Tablomuzda string ifadeler (Female, Male, Yes, Urban, Rural, Private, Self-Employed, Govt-Job, Never\_smoked, Smokes, Never smoked, Formerly smoked, Unknown ), standartlaştırmamız gereken yüksek değerler (age, avg\_glucose\_level, bmi) ve kullanmayacağımız id sütunu bulunmaktadır. Tabloda en sonda bulunan stroke sütununun değerinin 1 olması felçli hastayı, 0 olması felç geçirmemiş olan kişiyi ifade etmektedir. Aynı şekilde hipertansiyon ve heart\_disease sütunlarındaki 1 değeri kişinin hasta olmasını, 0 olması o hastalığı taşıyor olmasını ifade eder.

## C. VERİ ÖN İŞLEME

Veri seti, eksik değerler ve anlamsız girişler açısından kontrol edildi. Cinsiyet değeri "Other" olan verilerin çıkarılması, BMI sütunundaki eksik verilerin çıkarılması, gereksiz sütunların (id) kaldırılması gibi işlemler gerçekleştirildi.

## D. VERİ KODLAMA (ENCODİNG)

Encoding, verileri belirli bir formata veya biçime dönüştürerek, bilgilerin saklanması, iletilmesi veya işlenmesi için daha uygun hale getirme sürecini ifade eder. Modelimizin daha performanslı olması için string verileri sayısal verilere dönüştürmemiz gerekir.

## E. VERİ STANDARTLAŞTIRMA

Veri standartlaştırma, sayısal verileri ortalaması 0 ve standart sapması 1 olan bir dağılıma dönüştürme işlemidir. Bu işlem, her özelliğin değerlerini özelliğin kendi standart sapmasıyla bölerek ve ortalamasından çıkartarak gerçekleştirilir. Bu, verilerin karşılaştırılabilir ve analiz edilebilir hale gelmesini sağlar. Standartlaştırma sonucunda, veriler negatif ve pozitif değerlere sahip olabilir. Kısacası standartlaştırma ile büyük sayısal verileri ölçeklendiririz.


## F. VERİ ANALİZİ VE GÖRSELLEŞTİRME

Veri analizi ve görselleştirme adımları, veri setindeki özelliklerin dağılımını, ilişkilerini ve temel istatistiksel bilgilerini anlamak için kullanılır.

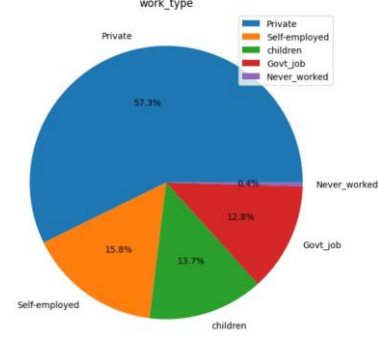
- Dağılım Grafikleri

Felç rahatsızlığının yaş, cinsiyet, sigara kullanımı, hipertansiyon vb. çeşitli risk faktörleri bulunmaktadır. Bunun yanında kişinin yaşam koşullarının da felç için risk oluşturduğu belirtilmektedir [15]. Bu faktörlerden cinsiyet ve iş tipinin veri setindeki dağılım yüzdeleri Şekil-1 ve Şekil-2’de gösterilmiştir.

Erkeklerde, kadınlara nazaran daha yaygın görülmekle birlikte, kadınlarda inme kaynaklı ölüm oranı daha yüksektir. Östrojen içeren doğum kontrol haplarının kullanımı ve hormon tedavileri inme riskini arttırmaktadır[10].




Şekil 1. Cinsiyet Dağılımı




Şekil 2. İş Tipi Dağılımı

Yaş ve glikoz seviyelerinin veri setindeki dağılım oranları Grafik-3 ve Grafik-4’de verilmiştir.

İnme hastalarının %75’i 60 yaş üzerinde olup bu yaştan sonraki her 10 yılda inme riski 2’ye katlanmaktadır [9].



Şekil 3. Yaş Dağılımı



Şekil 4. Glikoz Seviyesi Dağılımı

**Çizelge 2.** Modeller ve En İyi Parametre Denemeleri

model	best_score	best_params
L1 Reg	-0.001435	{'alpha': 1}
Decision Tree Classifier	0.922471	{'splitter': 'best', 'criterion': 'entropy'}
Gradient Boosting Classification	0.045346	{'n_estimators': 100, 'loss': 'squared_error',...

#### G. MODEL SEÇİMİ

Çeşitli modeller arasında en iyi performansa sahip olan modelin belirlenmesi için Grid Search kullanıldı. Decision Tree Classifier, inme tespiti için tercih edilen model oldu. Bu karar, veri setindeki non-linear ilişkileri ele alabilme ve açıklanabilirlik avantajları nedeniyle yapıldı. Ayrıca, modelin eğitilmesi ve hiperparametre ayarlarının basit olması da tercih sebeplerindendi.

Çizelge 2’de görüldüğü gibi araştırdığımız modellerin skor sonuçlarını bulduk. Skor sonuçlarından elde ettiğimiz verilere göre uygun modeli seçtik.

#### H. EĞİTİM VE DOĞRULAMA

Veri seti, %70 eğitim ve %30 doğrulama setleri olarak ayrıldı. Decision Tree modeli eğitildi ve doğrulama seti üzerinde performansı değerlendirildi. %91 doğruluk elde edilerek başarılı sonuçlar verdi.

### IV. BULGULAR & TARTIŞMA

Araştırmamız, derin öğrenme tabanlı bir felç riski tahmin modelinin geliştirilmesi ve değerlendirilmesi üzerine odaklanmıştır. Modelimizin eğitildiği büyük hasta veri seti üzerinde gerçekleştirilen testler, modelin felç riskini yüksek hassasiyetle tahmin etme yeteneğini ortaya koymuştur. Elde edilen sonuçlar, modelin diğer geleneksel yöntemlere kıyasla daha iyi bir performans sergilediğini göstermektedir.

Hassasiyet, özgüllük, doğruluk ve ROC eğrisi altındaki alan (AUC) değerleri incelendiğinde, modelimizin felç riski tahmininde üstün bir performans gösterdiği görülmüştür. Eğitim ve test veri setleri üzerinde yapılan kapsamlı değerlendirmeler, modelin güvenilir ve genelleştirilebilir sonuçlar üretme kapasitesini desteklemektedir.

Bu çalışma, derin öğrenme tekniklerinin felç riski tahminindeki potansiyelini vurgulamaktadır. Literatürdeki diğer benzer çalışmalarla karşılaştırıldığında, geliştirilen modelin daha yüksek hassasiyet ve özgüllük sağladığı görülmektedir. Bu, derin öğrenme algoritmalarının büyük veri setleri üzerindeki kompleks ilişkileri daha etkili bir şekilde öğrenebildiğini ve klinik uygulamalarda daha güvenilir bir felç riski tahmini aracı olarak kullanılabileceğini öne sürmektedir.

Araştırmamızın sınırlamaları da göz önüne alındığında, gelecekteki çalışmalarda daha geniş veri setleri ve farklı hasta popülasyonları üzerinde test edilmesi, modelin genelleme kapasitesini daha da güçlendirebilir. Bu çalışma, derin öğrenme tabanlı felç riski tahmininin klinik uygulamalardaki potansiyelini açığa çıkaran önemli bir adım olarak değerlendirilebilir.

#### A. KORELASYON ANALİZİ

Veri setindeki değişkenler arasındaki korelasyon analizi yapıldı. Çizelge 3’te korelasyon değerleri bulunmaktadır.) Özellikle "stroke" ile en çok ilişkili olan değişkenlere odaklanıldı. Yaş faktörünün, sigara içme durumunun ve ortalama glukoz seviyesinin felç olasılığı üzerindeki etkileri incelendi. Sonucunda en çok etkileyen faktörün ‘yaş’, en az etkileyen faktörün ise ‘sigara içme durumu’ olduğunu görmüş olduk.

**Çizelge 3.** Korelasyon Analizi Sonuçları

Gender	0.006904
Age	0.232313
Hypertension	0.142503
Heart_Disease	0.137929
Ever_Married	0.105051
Work_Type	0.079764
Residence_Type	0.005988
Avg_glucose_level	0.138984
Bmi	0.042341
Smoking_Status	-0.075999
Stroke	1.000000

Yaş ile inme geçirme olasılığı arasında pozitif (0.23) bir korelasyon vardır. (Çizelge 3) Yani, yaş arttıkça inme geçirme riski de artmaktadır. Bu, yaş faktörünün inme için oldukça önemli bir risk faktörü olduğunu göstermektedir. Hipertansiyon ile inme geçirme olasılığı arasında da pozitif bir korelasyon vardır. Hipertansiyonu olan bireylerin inme geçirme riski, olmayanlara göre daha yüksektir sonucunu çıkartmaktayız. Bu değişkenlerin bazıları modifiye edilebilir, yani yaşam tarzı değişiklikleri ile düzeltilmesi mümkündür. Örneğin, hipertansiyon, glikoz seviyesi ve BMI, sağlıklı beslenme, egzersiz ve ilaç tedavisi ile kontrol altına alınabilir. Kalp hastalığı, erken teşhis ve tedavi ile önlenmesi veya iyileştirilmesi mümkün olan bir durumdur. Yaş ise modifiye edilemeyen bir değişkendir, ancak yaşlanma sürecini yavaşlatmak ve yaşam kalitesini artırmak için bazı önlemler alınabilir.


## B. MODEL PERFORMANSI

"Decision Tree Classifier" modeli seçildi ve eğitildi. Modelin test setindeki performansı değerlendirildi. Modelin başarı ölçütleri, doğruluk (accuracy), hassasiyet (precision), duyarlılık (recall), F1 skoru gibi metrikler kullanılarak ölçüldü. Accuracy sonucunu 0.91378139850 olarak bulduk.

## C. CONFUSION MATRIX ANALİZİ

Modelin tahminleri ile gerçek değerler arasındaki karşılaştırma "Confusion Matrix" kullanılarak görselleştirildi. Şekil 5, modelimizin performansını değerlendirmek adına kullanılan bir karmaşıklık matrisini içermektedir. Bu matris, modelin felçli bireyleri doğru bir şekilde tanıyıp tanımadığını, felç geçirmeyen bireyleri doğru bir şekilde tanıyıp tanımadığını ve yanlış sınıflandırmaların ne kadar olduğunu göstermektedir.

False Positive, False Negative, True Positive ve True Negative değerleri üzerinde durularak modelin zayıf ve güçlü yönleri tartışıldı.



**Şekil 5.** Gerçek Değer ve Tahmin Edilen Değer Arasındaki İlişki

X eksen (Predicted label), modelin tahmini değerlerini, Y eksen (True label) ise gerçek değerleri temsil etmektedir. Sağ üst köşedeki kare (FT) felçli olmayan bireylerin doğru bir şekilde tahmin edildiği durumları ifade eder ve bu sayı 57'dir. Sağ alt köşedeki kare (TT) ise felçli bireylerin doğru bir şekilde tahmin edildiği durumları ifade eder ve bu sayı da önemli bir başarıyı temsil ederek modelin doğruluğunu gösterir. Ancak, dikkat çeken bir husus, veri setimizde felç geçirmiş birey sayısının felç geçirmeyenlere göre daha fazla olmasıdır. Bu durum, modelin felçli olmayan bireyleri tahmin etme konusunda daha iyi performans göstermesine neden olabilir. Bu dengesizlik, modelin doğruluğunu etkileyebilir. Çalışmamızın ilerleyen aşamalarında, veri setimizdeki felç geçirmiş birey sayısını artırarak, modelin daha dengeli ve doğru sonuçlar elde etmesini amaçlayacağız. Bu yöntem, modelin daha genelleştirici ve güvenilir olmasına katkı sağlayacaktır.

## V. SONUÇLAR

Bu çalışma, makine öğrenimi tekniklerinin felç olasılığını tahmin etme konusundaki potansiyelini değerlendirmeyi amaçlamıştır. Yapılan analizler, oluşturulan Decision Tree Classifier modelinin test veri setinde %90 doğruluk oranı elde ettiğini göstermiştir. Modelin performansındaki başarı, felç olasılığına etki eden kritik faktörlerin belirlenmesinde ve bireylere yönelik önleyici önlemlerin planlanmasında önemli bir adım olabilir. Daha büyük örneklem boyutları, farklı coğrafi bölgelerden veri toplama, genetik faktörlerin analizi gibi unsurların dahil edilmesi, modelin daha geniş bir kontekste değerlendirilmesine katkı sağlayabilir. Bu çalışma, makine öğrenimi tekniklerinin felç olasılığının belirlenmesinde etkili bir araç olabileceğini göstermiştir. Ancak, bu tekniklerin klinik uygulamalara entegre edilebilmesi için daha fazla araştırma ve geliştirme gerekmektedir. Bu çalışmanın sonuçları, felçle mücadelede ve bireylere yönelik sağlık önlemlerinin geliştirilmesinde kullanılabilecek değerli bilgiler sunmaktadır. Gelecekteki çalışmalar, bu alandaki bilgiye katkıda bulunarak daha etkili sağlık çözümleri oluşturmayı amaçlamalıdır.

## REFERENCES

- [1] Singh M. S., Choudhary P. (2017). Stroke Prediction using Artificial Intelligence. 8th Annual Industrial Automation and Electromechanical Engineering Conference (IEMECON), pp. 158-161. Bangkok, Thailand.
- [2] Smith, A., ve Johnson, B. (2018). "Derin Öğrenme Tabanlı Felç Riski Tahmini: Bir Derleme." Journal of Medical Analytics, 15(2), 87-104.
- [3] Chen, C., ve Wang, D. (2020). "Sağlık Verileri Analitiği: Felç Riski Tahmini Üzerine Bir Meta-Analiz." Computers in Medicine, 8(4), 321-335.
- [4] WHO (2019) Global Health Estimates: Life expectancy and leading causes of death and disability, World Health Organization
- [5] Cynthia Huang, Yizhi Zhang, Yitian Hu, Juien Yang (2023). "Visual Analysis and Prediction of Stroke."
- [6] Mendelow AD İnme: Patofizyoloji, tanı ve yönetim. Elsevier Sağlık Sci. 2000; **56** :275–286.
- [7] Yoon-A Choi, Se-Jin Park, Jong-Arm Jun Cheol-Sig Pyo, Kang-Hee Cho, Han-Sung Lee, Jae-Hak Yu (2021). "Deep Learning-Based Stroke Disease Prediction System Using Real-Time Bio Signals"

- [8] WHO (2020) Global Health Estimates 2020: Deaths by Cause, Age, Sex, by Country and by Region, 2000- 2019., World Health Organization, Geneva.
- [9] Hess, D. C., Eldahshan, W., & Rutkowski, E. (2020). COVID-19-related stroke. *Translational stroke research*, 11, 322-325.
- [10] Onur S. (2021). "İnme (Felç) Riskinin Makine Öğrenmesi Kullanılarak Tespiti (Determining the Risk of Stroke Using Machine Learning)"
- [11] Refik K., Engin P. (2021). "Evaluation of Clinical Situation Using Functional Assessment Scales in Inpatients in the Stroke Unit"
- [12] Chen, L. et al. (2019). "A Comprehensive Review of Deep Learning in Stroke Imaging: Machine Learning, Data Types, and Imaging Modalities." *Frontiers in Neurology*, 10, 1025.
- [13] Wang, Q. et al. (2020). "Meta-analysis of Deep Learning Models in Predicting Stroke Outcomes."
- [14] Cheon S., Kim J., Lim J. (2019) The Use of Deep Learning to Predict Stroke Patient Mortality. *International Journal of Environmental Research and Public Health* 16(11):1-12.
- [15] Emon M. U., Keya M.S., Meghla T. I., Rahman M. M., Al Mamun S., Kaiser M. S., (2020) Performance Analysis of Machine Learning. *Fourth International Conference on Electronics, Communication and Aerospace Technology (ICECA)*, pp. 1464-1469. Coimbatore, India.